

Relatório Técnico de Progresso

Semanas 1 e 2 — Engenharia de Dados & Pipeline ETL

Domínio: Música & Entretenimento

Abordagem: Spec-Driven Development

Estado: Transformação Concluída

1. Contexto e Objetivos Gerais

O presente projeto consiste no desenho e implementação de um pipeline de dados modular do tipo **Extract, Transform, Load (ETL)** adaptado para a ingestão e processamento eficiente de grandes volumes de dados musicais em ambiente local. O ecossistema integra dados do *Spotify Million Playlist Dataset (MPD)*, da *Spotify Web API* e da *MusicBrainz API*, visando cruzar dados estruturais de consumo com metadados biográficos ricos para extrair insights de negócio sobre tendências sonoras globais.

2. Semana 1: Módulo de Extração (Extract)

Nesta fase infraestrutural, o foco central esteve no desenvolvimento de conectores robustos e tolerantes a falhas, capturando os dados em formato bruto para constituir a **Camada Bronze**.

2.1. Conectividade a APIs e Gestão de Restrições

- **Spotify Web API:** Implementação do fluxo de autenticação e recolha de perfis e preferências de artistas.
- **MusicBrainz API (`extract_musicbrainz.py`):** Desenvolvido com controlo rigoroso de *Rate Limiting* (atraso intencional de 1.1 segundos por chamada) e reaproveitamento de conexões HTTP via `requests.Session()`, mitigando erros prematuros de fim de ficheiro (TLS/SSL Handshake) e bloqueios por parte dos servidores.

2.2. Ingestão de Alto Volume por Chunks (Spotify MPD)

Para processar o milhão de playlists contido no dataset estático do MPD sem esgotar a memória volátil (RAM), o script `extract_mpd.py` foi desenhado para efetuar o *streaming* direto do arquivo `.zip`. Os dados são lidos em fatias ordenadas (chunks de 1.000 playlists), passando por um filtro imediato que descarta dados não relacionados com os artistas monitorizados, otimizando o armazenamento físico logo no ponto de entrada.

3. Semana 2: Módulo de Transformação (Transform)

A segunda semana marcou a conversão e higienização dos dados extraídos usando a biblioteca **Pandas**, estabelecendo a transição entre dados brutos e conjuntos analíticos refinados.

3.1. Arquitetura de Dados Medalhão (Medallion Architecture)

O fluxo de dados foi segmentado de forma lógica e física para garantir a reprodutibilidade e modularidade do pipeline:

CAMADA BRONZE

Dados brutos em formato JSON isolados por fonte (originais de APIs e frações extraídas do ZIP).

CAMADA SILVER

Tabela unificada e limpa resultante do achatamento (flattening) e do **Left Join** explícito usando a chave `artist_name`.

CAMADA GOLD

Tabelas dimensionais agregadas, altamente leves e otimizadas para consumo analítico e visualização.

3.2. Controlo Automatizado de Data Quality

O script `transform_quality.py` atua como um portão de validação técnico, inspecionando o volume consolidado de **3.324.938 de linhas**. O resultado da auditoria foi registado nos seguintes termos:

Métrica de Qualidade	Estado	Registo de Auditoria / Justificação Técnica
Linhas Duplicadas	PASS	0 registos redundantes encontrados. Confirmação de integridade no processo de achatamento.
Outliers de Tempo	PASS	0 faixas com duração superior a 30 minutos. Ruídos e ficheiros corrompidos eliminados.
Valores Nulos (<code>`missing_values`</code>)	WARNING	Detetados nulos em dados biográficos (ex: <code>mb_end_date</code>). Validação humana conclui que a ausência de data final atesta que a esmagadora maioria dos artistas monitorizados continua no ativo, legitimando o dado.
Rácio de Matching	PASS	Apenas 3 artistas únicos (~54 linhas) falharam o emparelhamento de chaves com a MusicBrainz devido a divergências estritas de grafia (<0.001% de erro).

3.3. Sumarização Analítica (Camada Gold)

Para garantir o máximo desempenho na fase de visualização gráfica, a volumetria de mais de 3.3 milhões de linhas foi agregada em três visões estratégicas de escassos kilobytes:

- **Popularidade de Artistas (``dim_artist_popularity_gold``):** Identifica a dominância absoluta de artistas como *Drake* (847.160 aparições em 203.355 playlists) e o alcance expandido de seguidores.
- **Frequência de Géneros (``dim_genre_ranking_gold``):** Extração e explosão de listas de tags da MusicBrainz, mapeando um pódio liderado de forma destacada por *Hip Hop*, *Pop* e *Trap*.
- **Distribuição Geográfica (``dim_country_distribution_gold``):** Consolidação de faixas por país de origem do artista, demonstrando a concentração de consumo centrada no eixo americano (US) e canadiano (CA).

Próximo Passo — Semana 3 (Load): Com o encerramento das transformações, o pipeline avançará para a criação do modelo físico de dados (Esquema Relacional/Estrela) e persistência das tabelas Gold em base de dados local recorrendo ao motor **DuckDB** ou **SQLite**.