

Relatório Técnico de Progresso

Semanas 1, 2 e 3 — Engenharia de Dados & Pipeline ETL

Domínio: Música & Entretenimento Abordagem: Spec-Driven Development Estado: Carregamento Concluído (100%)

1. Contexto e Objetivos Gerais

O presente projeto consiste no desenho e implementação de um pipeline de dados modular do tipo **Extract, Transform, Load (ETL)** adaptado para a ingestão e processamento eficiente de grandes volumes de dados musicais em ambiente local. O ecossistema integra dados do *Spotify Million Playlist Dataset (MPD)*, da *Spotify Web API* e da *MusicBrainz API*, visando cruzar dados estruturais de consumo com metadados biográficos ricos para extrair insights de negócio sobre tendências sonoras globais.

2. Semana 1: Módulo de Extração (Extract)

Nesta fase infraestrutural, o foco central esteve no desenvolvimento de conectores robustos e tolerantes a falhas, capturando os dados em formato bruto para constituir a **Camada Bronze**.

2.1. Conectividade a APIs e Gestão de Restrições

- **Spotify Web API:** Implementação do fluxo de autenticação e recolha de perfis e preferências de artistas.
- **MusicBrainz API (`extract_musicbrainz.py`):** Desenvolvido com controlo rigoroso de *Rate Limiting* (atraso intencional de 1.1 segundos por chamada) e reaproveitamento de conexões HTTP via `requests.Session()`, mitigando erros prematuros de fim de ficheiro (TLS/SSL Handshake) e bloqueios por parte dos servidores.

2.2. Ingestão de Alto Volume por Chunks (Spotify MPD)

Para processar o milhão de playlists contido no dataset estático do MPD sem esgotar a memória volátil (RAM), o script `extract_mpd.py` foi desenhado para efetuar o *streaming* direto do arquivo `.zip`. Os dados são lidos em fatias ordenadas (chunks de 1.000 playlists), passando por um filtro imediato que descarta dados não relacionados com os artistas monitorizados, otimizando o armazenamento físico logo no ponto de entrada.

3. Semana 2: Módulo de Transformação (Transform)

A segunda semana marcou a conversão e higienização dos dados extraídos usando a biblioteca **Pandas**, estabelecendo a transição entre dados brutos e conjuntos analíticos refinados.

3.1. Arquitetura de Dados Medalhão (Medallion Architecture)

O fluxo de dados foi segmentado de forma lógica e física para garantir a reprodutibilidade e modularidade do pipeline:

CAMADA BRONZE Dados brutos em formato JSON isolados por fonte (originais de APIs e frações extraídas do ZIP).	CAMADA SILVER Tabela unificada e limpa resultante do achatamento (flattening) e do Left Join explícito usando a chave <code>artist_name</code> .	CAMADA GOLD (CSVS) Tabelas dimensionais agregadas, altamente leves e otimizadas para consumo analítico e visualização.
---	---	--

3.2. Controlo Automatizado de Data Quality

O script `transform_quality.py` atua como um portão de validação técnico, inspecionando o volume consolidado de **3.324.938 de linhas**. O resultado da auditoria foi registado nos seguintes termos:

Métrica de Qualidade (Transform)	Estado	Registo de Auditoria / Justificação Técnica
Linhas Duplicadas	PASS	0 registos redundantes encontrados. Confirmação de integridade no processo de achatamento.
Outliers de Tempo	PASS	0 faixas com duração superior a 30 minutos. Ruídos e ficheiros corrompidos eliminados.
Valores Nulos ('missing_values')	WARNING	Detetados nulos em dados biográficos (ex: <code>mb_end_date</code>). Validação humana conclui que a ausência de data final atesta que a esmagadora maioria dos artistas monitorizados continua no ativo, legitimando o dado.
Rácio de Matching	PASS	Apenas 3 artistas únicos (~54 linhas) falharam o emparelhamento de chaves com a MusicBrainz devido a divergências estritas de grafia (<0.001% de erro).

3.3. Sumarização Analítica (Camada Gold)

Para garantir o máximo desempenho na fase de visualização gráfica, a volumetria de mais de 3.3 milhões de linhas foi agregada em três visões estratégicas de escassos kilobytes:

- **Popularidade de Artistas ('dim_artist_popularity_gold')**: Identifica a dominância absoluta de artistas como *Drake* (847.160 aparições em 203.355 playlists) e o alcance expandido de seguidores.
- **Frequência de Géneros ('dim_genre_ranking_gold')**: Extração e explosão de listas de tags da MusicBrainz, mapeando um pódio liderado de forma destacada por *Hip Hop*, *Pop* e *Trap*.
- **Distribuição Geográfica ('dim_country_distribution_gold')**: Consolidação de faixas por país de origem do artista, demonstrando a concentração de consumo centrada no eixo americano (US) e canadiano (CA).

4. Semana 3: Módulo de Carregamento (Load)

A terceira semana marcou a transição final dos ficheiros planos soltos para uma infraestrutura de ****Base de Dados Relacional e Analítica (OLAP)**** baseada no motor ****DuckDB****, consolidando o **Star Schema** estruturado para a fase de visualização.

4.1. Seleção Tecnológica e Engenharia de Performance

O motor **DuckDB** foi selecionado devido à sua arquitetura colunar nativa focada em queries analíticas e à sua capacidade de processar volumes massivos localmente com consumo otimizado de memória. A integração é realizada de forma direta no ficheiro de persistência física `data/gold/music_analytics.db`, eliminando a dependência de processos voláteis em RAM.

Durante o processo de carga, foi implementado um mecanismo de **Tipagem Robusta por Exceção**: as colunas de data biográfica (`mb_begin_date` e `mb_end_date`) foram mapeadas explicitamente como `VARCHAR`. Esta decisão de engenharia impediu falhas críticas de conversão geradas por anos truncados fornecidos pelas APIs (como o ano isolado 1969 do artista *Papillon*), conferindo resiliência ao pipeline.

4.2. Execução da Carga em Massa (Bulk Load)

O script `load_to_db.py` orquestrou o carregamento de forma síncrona através do leitor otimizado do DuckDB (`read_csv_auto`). Foram estruturadas e preenchidas as seguintes tabelas relacionais:

- `fact_playlists_tracks`: Tabela mãe de factos que absorveu a totalidade do schema estendido da camada Silver.
- `gold_artist_popularity`: Dimensão relacional contendo os índices consolidados de visibilidade dos artistas.
- `gold_genre_ranking`: Dimensão normalizada de tendências e categorias sonoras.
- `gold_country_distribution`: Tabela analítica de distribuição por soberania geográfica.

4.3. Auditoria de Data Quality Pós-Carga (SQL)

A validação de integridade foi executada em tempo real sobre o motor de base de dados através de asserções SQL explícitas, alcançando os seguintes resultados de conformidade técnica:

Métrica de Auditoria (Load)	Estado	Resultado Obtido / Evidência Técnica
Integridade Quantitativa de Carga	PASS	3.324.938 de 3.324.938 linhas inseridas e validadas sem truncagem ou perda de linhas (Duração: 7.25s).
Conformidade da Dimensão Artistas	PASS	26 registos analíticos de topo consolidados e indexados com chaves primárias estáveis.
Integridade Referencial (Chaves Estrangeiras)	PASS	0 registos órfãos detetados via query SQL de exclusão (LEFT JOIN). Coesão de chaves a 100%.

Próximo Passo — Semana 4 (Visualization): Com a base de dados DuckDB completamente carregada, validada e trancada, a infraestrutura está pronta para ser conectada à ferramenta de visualização de forma a construir o painel analítico final (Storytelling dos dados).